Active Learning - 主动学习

孙　欣

阿里飞猪

目录

1. 背景知识

2. 摘要 - 贡献点

3. 模型 - 方法

4. 评测

background

背景知识

《Active Learning Literature Survey》

· 前提

要分类大量未标记的数据, 但没有可用于训练分类器的标记数据, 且由于时间 / 金钱成本限制, 很难标记大量数据用于训练

· 关键假设

是否允许学习算法从大量未标注样本中选择”高信息”的数据, 它将在训练数据较少情况下获得同等或更好效果

· 目标

在达到同样效果前提下, 尽量减少训练数据量, 从而降低标签成本

背景知识

某些情况下, 未标记的数据非常丰富, 标记的数据非常少, 并且手动标记数据的成本非常高(时间和金钱). 我们可以让算法主动选择应标记哪些数据, 然后将这些数据发送给专家进行人工标记, 最后将这些新标记数据添加到训练数据集中重新训练模型.

背景知识

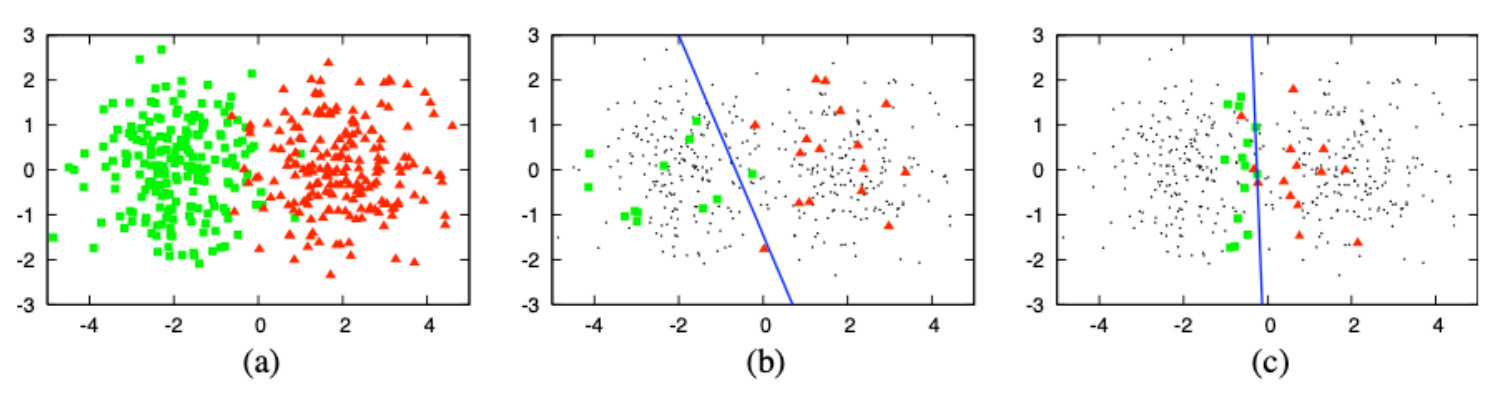

(a) 400个数据点, 二分类.

(b) A lr model trained with 30 labeled instances randomly drawn from the problem domain(70% accuracy).

(c) A lr model trained with 30 actively queried instances using uncertainty sampling (90%).

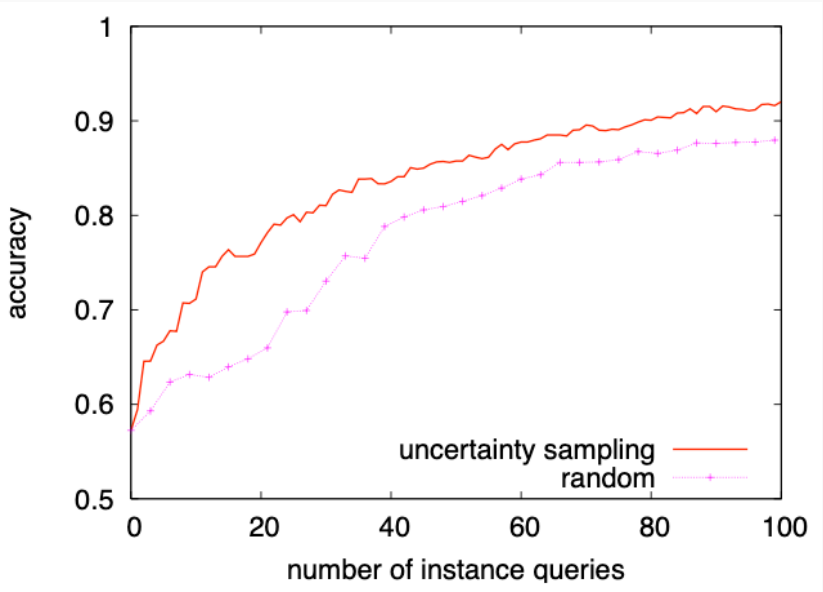

背景知识

Active learning 组成

主动学习算法可以通过以下五个组件来建模：

$$A = (C, L, S, Q, U)$$

其中,
C 是一个分类器或一组分类器;
L 是一组标记的训练样本;
Q 是一种查询功能或策略, 用于查询未标记样本中具有大量信息的样本;
U 是整个未标记的样本集;
S 是可以标记未标记样品的专家.

背景知识

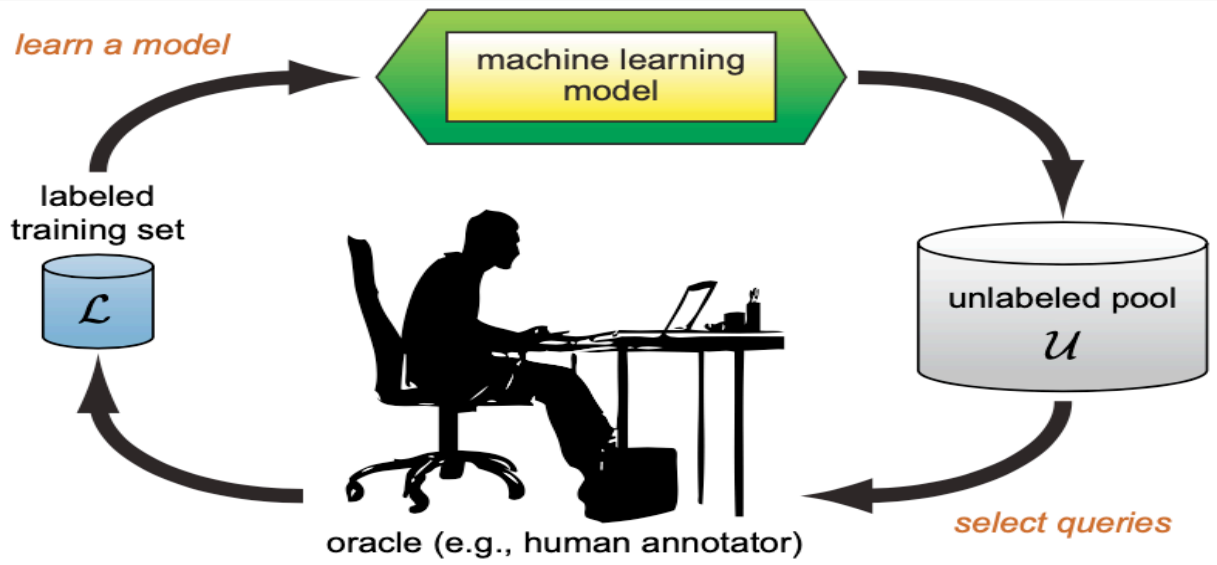

· 第一阶段：初始化阶段. 专家随机选择一小部分未标记的样本，并将其标记为训练集，以建立初始分类器模型

· 第二阶段：循环查询阶段. 在未标记的样本集中，选择某些未标记的样本进行标记，然后根据特定的查询条件选择出的新未标注样本添加到训练样本集中，给专家进行人工标注，并对分类器进行重新训练，直到达到训练停止标准为止

背景知识

Active learning 场景 - 类别

- Membership query synthesis
- Stream-Based selective sampling
- Pool-Based sampling

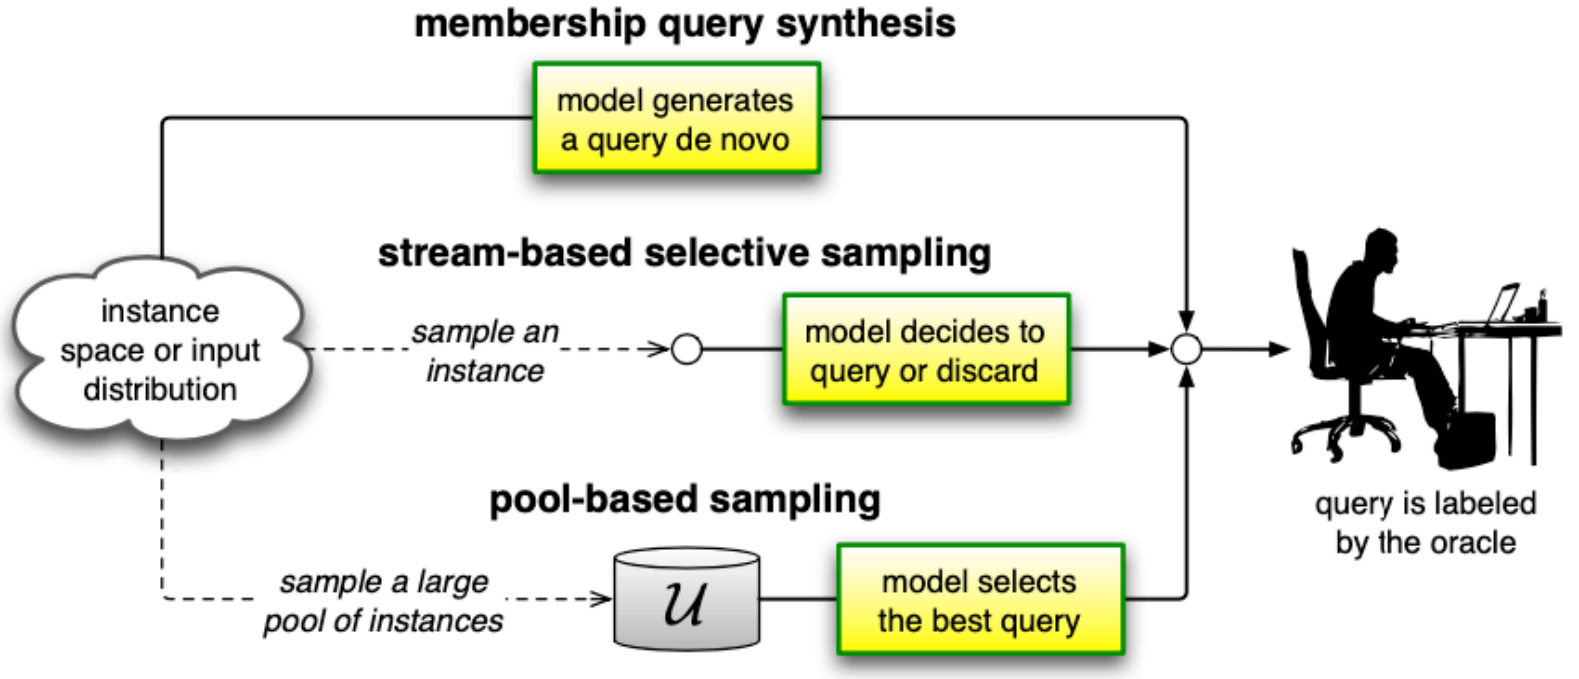

背景知识

Query / Selection Strategy

- Uncertainty Sampling (Least confidence, Margin, Entropy, etc.)
- Expected Model Change - Error Reduction - Variance Reduction
- Density-Weighted Methods
- Query-By-Committee

Abstract

摘要 - 贡献点

《Learning Loss for Active Learning》

1. 给目标网络新增一个参数量很小的模块“损失预测模块” , 用于预测模型对无标签数据预测结果的损失值, 它可以直接应用到任何使用深度网络的任务上

2. 该模型是任务无偏的 , 与具体目标没有关系. 文章使用了三个学习任务对新方法进行测评, 包括回归问题, 分类问题以及回归和分类的混合问题

Approaches

模型 - 方法

Notation	Explanation
Θ_{target}	target model 目标模型
Θ_{loss}	loss prediction module 损失预测模块
$\hat{y} = \Theta_{target}(x)$	目标模型的预测值
$l = L_{target}(\hat{y}, y)$	目标模型预测的损失
h	x的特征集合，是Θ_{target}隐藏层的中间特征
$\hat{l} = \Theta_{loss}(h)$	损失预测模块对损失的预测值
U_N	无标签数据池
N	无标签数据池的大小
K	每一轮从无标签数据池中查询的个数
L_K^0	初始有标签数据，即从U_N均匀地抽K个
U_{N-K}^0	初始化后的无标签数据池
$L_{(T+1)K}^T$	T轮查询后的有标签数据集
$U_{N-(T+1)K}^T$	T轮查询后的无标签数据池

模型 - 方法

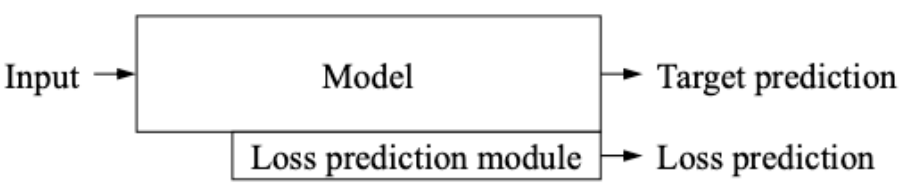

(a) A model with a loss prediction module

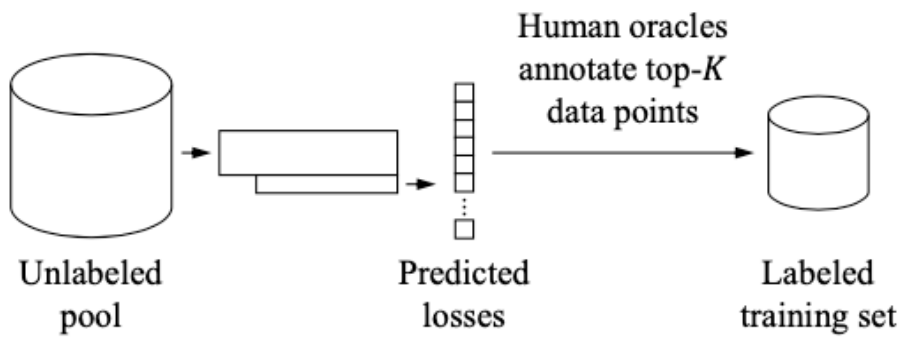

(b) Active learning with a loss prediction module

(a) 展示的是从输入数据Input到任务网络给出的Target prediction和利用任务网络中间特征传进误差预测模块给出Loss prediction

(b) 图表示的是通过Loss prediction的大小关系，挑选出U集中的误差预测最大的K个无标签数据点，送给专家进行标注后归入L集，更新得到有标签数据集L和无标签数据集U

Note: 训练整个模型用的是有标签数据，无标签数据是在训练更新参数后传入模型输出预测的损失，按照大小选择数据进行查询

方法 - Loss Prediction Module

作者希望把训练损失预测模块的计算代价最小化， 且Loss Prediction module是无偏的, 可以适应于任何下游任务.

- 比任务模型(target model)小很多.
- 和任务模型同步学习(jointly), 不需要额外的步骤.

方法 - Loss Prediction Module

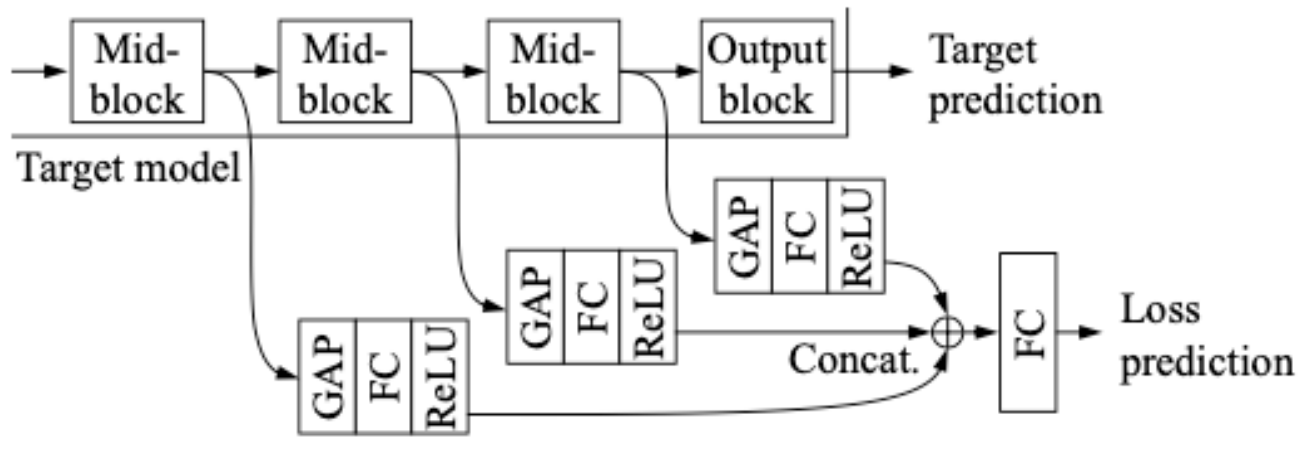

- Target prediction的网络在图像上部, 作者将深度网络分为若干中间块(Mid-block), 依次提出这些层特征作为输入, 传递到下方的小网络当中, 最后汇聚到一个全连接层(FC Layer), 得到损失预测值(scalar value).
- 在每一个中间层特征传入的小网络中， 包括一个全局平均池化层(GAP)， 一个全连接层以及通过ReLU激活. 通过在把所有中间特征汇聚到全连接层前的这些处理, 作者将中间特征降维到固定的维度128.
- 另外, 作者表示如果把这个损失预测模块做的更深更广, 表现变化不大.

方法 - Learning Loss

根据前面的定义和符号，在第 T 步主动学习阶段，我们有标签数据集$L^T_{(T+1)K}$ 和 无标签数据集$U^T_{N-(T+1)K}$.

这一步的目的是训练出两个模型: $\{\Theta^T_{target}, \Theta^T_{loss}\}$

$$L_{\text{target}}(\hat{y}, y) + \lambda \cdot L_{\text{loss}}(\hat{l}, l)$$

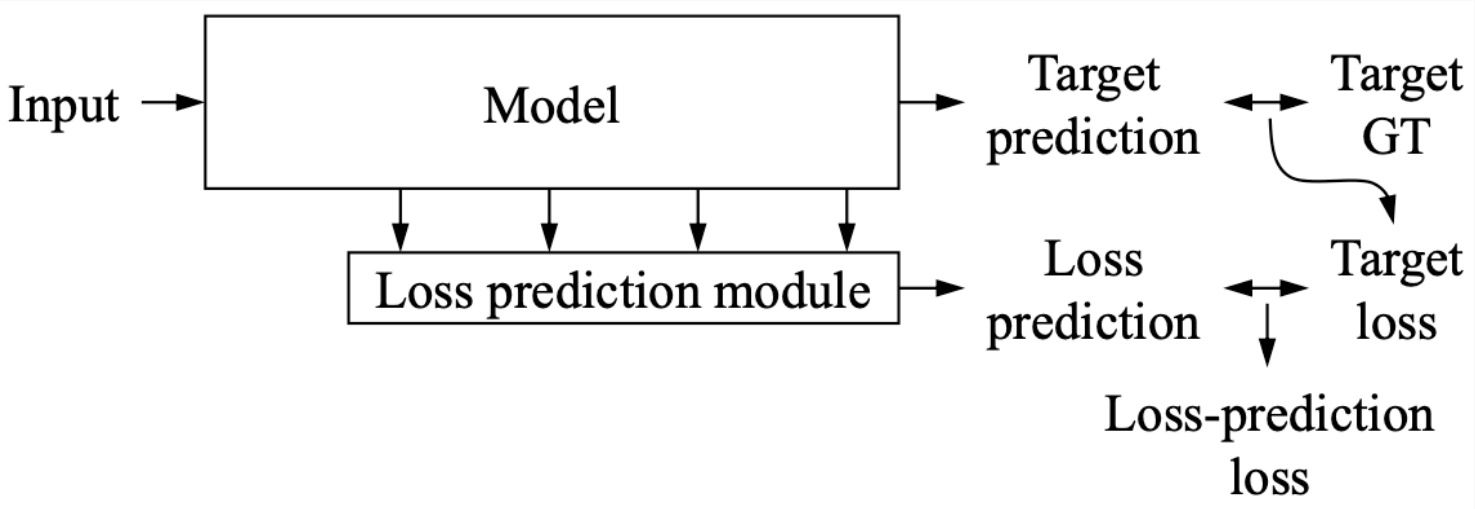

方法 - Learning Loss

MSE Loss 不适用

随着真实的l值在一次次训练中下降, $L_{loss}(\hat{l}, l) = (\hat{l} - l)^2$的减小似乎不一定代表损失预测模块对于损失预测的能力越来越强. 因为$\hat{l}$只需要适应l的变化, 而不需要更加贴合这个真实值就可以在迭代中造成 MSE 下降

方法 - Learning Loss

作者设计了一种新的Loss, 可以无视l的量纲大小变化. 通过对比一对样本来构造新的损失函数.

在一个batc size 为 B的batch中，我们可以得到 B/2个样本对$\{x^p = (x_i, x_j)\}$, 作者通过计算这一对数据对中的预测损失差异来度量损失函数值

$$L_{loss}(\hat{l}^p, l^p) = max(0, -I_{(l_i,l_j)} * (\hat{l}_i - \hat{l}_j) + \xi)$$

$$I_{(l_i,l_j)} = \begin{cases} +1, & if\ l_i > l_j \\ -1, & otherwise \end{cases}$$

其中 ξ是一个预先设定的正间隔， 下标 p 指的就是样本对(i,j), 对于上述式子的理解, 当$l_i > l_j$时, 只有$\hat{l}_i > \hat{l}_j + \xi$时, 才有loss值为0, 其他情况下损失值不为零, 以期增大$\hat{l}_i$, 并且减小$\hat{l}_j$.

$$\frac{1}{B}\sum_{(x,y)\in\mathcal{B}^s} L_{\text{target}}(\hat{y}, y) + \lambda\frac{2}{B}\cdot\sum_{(x^p,y^p)\in\mathcal{B}^s} L_{\text{loss}}(\hat{l^p}, l^p)$$

$$\text{s.t.} \quad \begin{aligned} \hat{y} &= \Theta_{\text{target}}(x) \\ \hat{l^p} &= \Theta_{\text{loss}}(h^p) \\ l^p &= L_{\text{target}}(\hat{y^p}, y^p). \end{aligned}$$

Evaluation

评测

作者在Image Classification, Object Detection, Pose Estimation三种不同的任务和数据集上测试. 虽然是CV任务, 但是因为模型是任务无偏的, 所以在NLP或其他需要标注数据的DL任务上仍适用.

下图是在Image Classification上的结果.

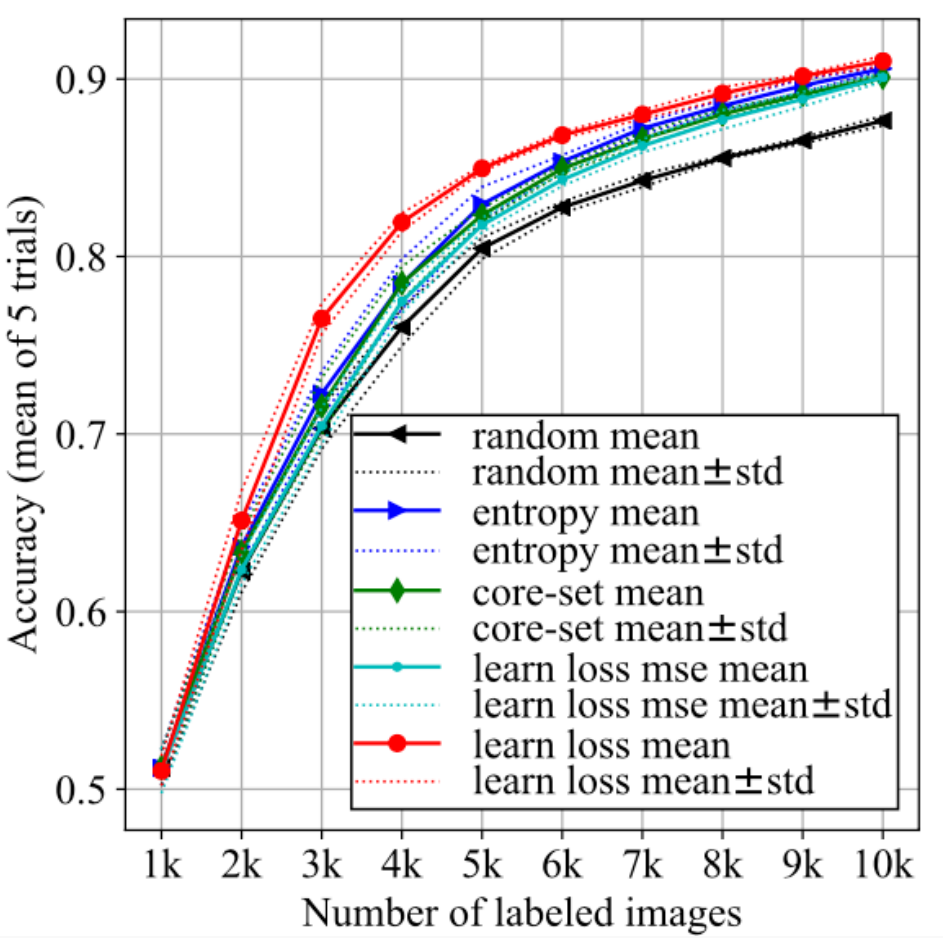

Further

Further

Selection Strategy

- **Uncertainty:** Least Confidence, Margin, Entropy, Loss, Variance, etc
- **Diversity:** sample similarity, etc
- **Density:** sample distribution, etc

……

Question ?